

五一数学建模竞赛

承 诺 书

我们仔细阅读了五一数学建模竞赛的竞赛规则。

我们完全明白，在竞赛开始后参赛队员不能以任何方式（包括电话、电子邮件、网上咨询等）与本队以外的任何人（包括指导教师）研究、讨论与赛题有关的问题。

我们知道，抄袭别人的成果是违反竞赛规则的，如果引用别人的成果或其它公开的资料（包括网上查到的资料），必须按照规定的参考文献的表述方式在正文引用处和参考文献中明确列出。

我们郑重承诺，严格遵守竞赛规则，以保证竞赛的公正、公平性。如有违反竞赛规则的行为，我们愿意承担由此引起的一切后果。

我们授权五一数学建模竞赛组委会，可将我们的论文以任何形式进行公开展示（包括进行网上公示，在书籍、期刊和其他媒体进行正式或非正式发表等）。

参赛题号（从 A/B/C 中选择一项填写）： C

参赛队号： T3844544691213

参赛组别（研究生、本科、专科、高中）： 本科

所属学校（学校全称）： 南京林业大学

参赛队员： 队员 1 姓名： 荣禄丞

队员 2 姓名： 傅翔宇


队员 3 姓名： 黄子谊

联系方式： Email: lucheng.rong@outlook.com 联系电话： 19552239585

日期： 2025 年 5 月 4 日

（除本页外不允许出现学校及个人信息）

五一数学建模竞赛



《基于机器学习的社交媒体用户互动行为预测模型研究》

关键词：社交媒体分析；用户行为预测；XGBoost 回归；双通道推荐模型；SIR 传播模型；分时段活跃度预测。

摘要：

本研究针对社交媒体平台用户与博主互动行为的预测需求，构建了一套多任务协同的数学模型体系，旨在解决四个核心问题：（1）博主新增关注数预测；（2）用户新关注行为预测；（3）用户在线状态及互动博主预测；（4）用户分时段在线行为及互动博主预测。

针对问题一，我们采用 **XGBoost 回归模型**，基于 2024 年 7 月 11 日至 20 日的历史互动数据，提取时序特征（**滑动窗口统计**、**移动平均**）和周期性特征（**星期几效应**），预测 7 月 21 日各博主的新增关注数，并筛选出 TOP5 高增长博主（博主 B21 预测新增 500.4 关注）。模型通过**正则化项**控制过拟合，特征重要性分析显示日平均观看量和点赞总数对预测贡献显著。

问题二结合历史与实时数据（7 月 11-22 日），提出**双通道预测框架**：个性化通道通过**逻辑回归**建模用户从观看、点赞到关注的转化规律，热度通道利用**改进的 SIR 模型**量化博主传播力，最终融合地理匹配系数 $\epsilon=0.2$ 和时段敏感修正因子 $\eta=0.01$ 输出关注概率。实验表明，以用户 U7 为例，其在 7 月 22 日新增关注博主 B23、B27、B7，验证了模型的细粒度预测能力。

问题三通过**线性加权融合目标星期活跃次数**（权重 0.4）、活跃天数（权重 0.3）等特征，预测用户在线概率（ $P \geq 0.5$ 判定为在线），并基于**综合互动指数推荐** TOP3 博主。例如，用户 U9 的推荐博主为 B13、B24、B3，反映了用户历史偏好。

问题四引入分时段动态建模，统计用户在星期二（即 7 月 23 日）各小时的活跃频率（如用户 U10 在 01:00-02:00 时段活跃概率最高），结合全局热度指标和个性化互动基数，生成**时段化推荐列表**。结果显示，以用户 U1951 为例，其在 16:00-17:00 时段与博主 B21 互动概率最高，凸显了时段特异性。

模型评价表明，XGBoost 在问题一中表现优异（ $R^2=0.89$ ），但对长期时序依赖捕捉不足；问题四的热度指标存在马太效应，通过引入衰减因子优化后，新晋博主曝光率提升 12%。未来可结合 LSTM 增强时序建模，或引入图神经网络挖掘用户-博主二部图关系。本研究为社交媒体平台的精准推荐和用户行为分析提供了可扩展的解决方案。

一、问题重述

1.1 问题背景

近年来，社交媒体平台已成为人们社交互动与信息获取的重要渠道。博主通过创作高质量内容吸引用户关注，而用户可以经由观看、点赞、评论、关注等行为参与互动。平台通过分析用户与博主的历史交互数据，可以助力博主提高内容质量，同时也能够优化内容推荐策略，提升用户体验。

1.2 问题提出

现某个社交媒体平台为预测用户行为和优化内容推荐方法，对某个时间段的现有用户与博主之间的互动行为关系进行深入的分析。设数字 1、2、3、4 分别为用户对博主内容的观看、点赞、评论，以及对博主的关注。假定该平台用户和博主数量固定，没有新账号加入和老账号注销，并且用户和博主的互动关系建立后不再变化。

现在需要建立数学模型解决下列问题：

- (1) 基于该平台在 2024.7.11-2024.7.20 之间的用户与博主互动数据，预测各博主在 2024.7.21 的新增关注数，并给出新增关注数最多的 5 位博主。
- (2) 结合 2024.7.11-2024.7.20 之间的用户与博主互动数据和 2024.7.22 用户与博主互动数据，预测用户在 2024.7.22 的新关注行为。
- (3) 基于该平台在 2024.7.11-2024.7.20 之间的用户与博主互动数据，预测指定用户 2024.7.21 的在线状态及可能互动的 TOP3 博主。
- (4) 综合分析该平台在 2024.7.11-2024.7.20 之间的用户与博主互动数据，预测指定用户 2024.7.23 的在线时段及对应时段互动数最高的 3 位博主。

二、问题分析

2.1 问题一的分析

问题一的主要研究目标在于利用 2024 年 7 月 11 日至 20 日的用户交互记录，预测特定博主群体在 7 月 21 日可能获得的新增关注量。这个预测问题具有典型的时序特征与用户行为转化特性。为实现准确预测，我们采用以下技术路径：首先建立用户与博主的交互关系矩阵，对点赞、评论、关注这些表示用户观看内容的行为进行量化分析，从中提取用户活跃度变化曲线、近周期行为密度分布、交互序列关联特征等关键指标。继而运用 XGBoost 等集成学习回归算法，通过特征重要性分析构建预测模型。模型训练完成后，我们对全量博主进行关注增量预测，通过排序算法选取 TOP5 高增长博主，并按要求格式化输出预测结果。

2.2 问题二的分析

问题二的核心任务是预测特定用户在 2024 年 7 月 22 日的新增关注行为。相较于问题一来说，该任务具有两个显著特点：一是预测时间跨度更短，二是预测对象细化到个体用户层面。这种细粒度预测要求模型具备实时捕捉用户兴趣动态的能力，需要综合考量用户在 2024 年 7 月 22 日实时行为数据及其历史行为特征。

具体来说，用户当天的互动行为可作为即时兴趣信号，而历史行为数据则反映了用户的长期偏好。所以，我们需要构建一个具体的、可以用分数表示的模型：首先提取用户短期行为特征和长期偏好特征，然后通过机器学习方法学习用户从"观看、点赞、评论"到"关注"的行为转化规律。

在模型实现上，可选用逻辑回归等分类算法进行建模。通过设定合适的概率阈值，模型可识别出潜在的关注事件，最终输出指定用户可能新增关注的博主 ID 列表。这种方法既能捕捉用户的实时兴趣变化，又能兼顾其长期行为偏好，从而实现精准的个性化预测。

2.3 问题三的分析

问题三的建模任务包含两个递进环节：首先预测用户在 7 月 21 日的在线状态，进而推断其最可能互动的三位博主。我们将分为两方面讨论：

2.3.1 在线状态预测

作为第一层预测任务，需要构建用户活跃度判别模型。通过加权融合特征，计算在线概率。核心特征应包括用户的时序行为特征，即历史连续活跃天数、最近登录时间间隔和使用习惯特征，即分时段活跃频率、日均使用时长等，重点捕捉用户活跃模式的时序规律。

2.3.2 互动博主预测

基于在线预测结果，需建立用户与博主交互的偏好模型：

构建用户历史交互特征矩阵，包含观看、点赞、评论、关注行为的加权评分，然后通过协同过滤或矩阵分解方法挖掘潜在偏好，最后采用行为相似度计算生成博主推荐排序。

这个阶段的关键是要区分不同互动行为的权重，通过综合评分机制预测 top3 互动博主。

2.4 问题四的分析

问题四将预测任务细化至小时级动态建模，要求对用户 7 月 23 日全天 24 小时进行分时段预测，具体包含两个层级：一是判断用户在每个小时内是否在线，二是针对预测为活跃的时段，推测用户可能互动的博主及频次。首先，我们应基于历史数据，利用分时段多任务学习模型、时序分类器等来统计用户在各时段的行为频率，构建用户时段分布向量，进而预测用户在某一时段的上线概率。然后构建综合评分函数，并在预测活跃时段启动最优匹配算法，构建该时段内用户与博主之间的行为倾向评分模型，最后输出 Top3 博主推荐列表及预期互动强度。

三、模型假设

1.假设博主关注数变化可通过差分平稳化。

- 2.假设用户历史互动对未来行为有着直接影响。
- 3.假设在预测期内没有突发事件影响用户行为。
- 4.假设该平台用户和博主数量固定，没有新账号加入和老账号注销。
- 5.假设用户和博主的互动关系建立后不再变化。

四、 符号说明

表 1 符号说明

符号	意义
N	统计的时间长度
$\hat{y}_i$	模型对样本 i 的预测值
ω_j	第 j 个叶节点的权重
γ	正则化系数
λ	正则化系数
f_t	第 t 棵树的结构和权重
$\mathcal{F}$	决策树集合
R^2	决定系数
θ	阈值
β	行为权重向量

五、 模型建立求解

5.1 题目 1

5.1.1 模型的建立

首先，我们要对数据进行预处理与聚合。提取每个博主每日新增关注数，构建时间序列数据集，生成每日互动统计量。用户对某博主的单次行为：观看，点赞，评论，关注我们假定为数字 1、2、3、4，遂得到：

$$\text{观看次数}^{(t)} = \sum_{i \in \text{用户}} \mathbb{I}(\text{行为}_i = 1), \text{日期} = t \tag{1}$$

$$\text{新增关注数}^{(t)} = |\{\text{用户ID} \mid \text{行为} = 4 \text{ 且 首次关注}\}| \tag{2}$$

接着，基于历史数据构造预测特征，用于预测次日新增关注数 $y^{(t+1)}$ 。先定义窗口长度 N （如 3 天、7 天），计算过去 N 天的统计量，据以下公式得出这段时间的日平均观看量以及点赞总数：

$$\text{watch_mean}_N^{(t)} = \frac{1}{N} \sum_{k=1}^N \text{观看次数}^{(t-k)} \quad (3)$$

$$\text{like_sum}_N^{(t)} = \sum_{k=1}^N \text{点赞次数}^{(t-k)} \quad (4)$$

为避免未来信息泄露，这里直接使用前 k 天的原始值：

$$\text{follow_lagk}^{(t)} = \text{新增关注数}^{(t-k)} \quad (5)$$

考虑到周末对于用户使用的影响，我们需要考虑时间特征。可以将日期转换为星期几，这里令周一=0，周二=1，以此类推，然后用判别式判断其是否为周末：

$$\text{星期}^{(t)} = f_{\text{weekday}}(\text{日期}^{(t)}) \quad (6)$$

$$\text{是否周末}^{(t)} = \mathbb{I}(\text{星期}^{(t)} \geq 5) \quad (7)$$

为观察其趋势特征，可引入移动平均 MA 以观察过去 N 天新增关注数的平滑值：

$$\text{follow_ma}_N^{(t)} = \frac{1}{N} \sum_{k=1}^N \text{新增关注数}^{(t-k)} \quad (8)$$

然后，我们可以基于 XGBoost 回归进行模型构建，采用均方误差 MSE 作为基础损失函数量化模型预测结果与真实值之间差异：

$$\mathcal{L}(\theta) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{t=1}^T \left(\gamma \cdot \text{叶节点数} + \frac{1}{2} \lambda \sum_{j=1}^m \omega_j^2 \right) \quad (9)$$

其中前半部分为最小化预测值与真实值的均方误差 MSE，后半部分为正则化项，其作用为防止过拟合。

对于输入样本 x_i ，模型的最终预测值为所有决策树预测值的加权和：

$$\hat{y}_i = \sum_{t=1}^T f_t(x_i), \quad f_t \in \mathcal{F} \quad (10)$$

其中 T 为决策树的总数量。

最后，基于时间序列数据的特性，采用严格的时间先后顺序进行数据划分。将 2024-07-11 至 2024-07-19 这 9 天的时间作为训练集。对于每个时间点 t ，使用 $[t-k, t-1]$ 窗口期的特征预测 $y^{(t)}$ 。验证集设为 2024-07-20，测试集设为 2024-07-21。

根据以上模型，可以得到以下模型元素权值图：




图 1 模型特征重要性图

5.1.2 模型的求解

对最后一天（2024-07-20）的数据，计算所有历史统计特征：

$$X_{\text{last}} = [\text{watch_mean}_N^{(t)}, \text{like_sum}_N^{(t)}, \text{星期}^{(t)}, \dots] \quad (11)$$

由此得到新增关注数：

$$\hat{y}_{2024-07-21} = \text{XGBoost}(X_{\text{last}}) \quad (12)$$

根据以上模型，能得到博主互动特征分布图：




图 2 博主互动特征分布图

根据所得结果，按预测值降序排列，取数值最高的前 5 名博主：

$$\text{Top5} = \arg \max_{\text{博主ID}} \hat{y}_{2024-07-21} \quad (13)$$




图 3 TOP5 博主关注趋势折线图

表 2 题目 1 结果

排名	1	2	3	4	5
博主 ID	B21	B5	B60	B15	B13
新增关注数	500.4	476.1	384.4	363.0	267.3

其结果用如下图表示：




图 4 题目 1 结果柱形图

5.2 题目 2

5.2.1 模型的建立

首先要量化用户的行为特征,定义用户历史行为的时间衰减系数：

$$w_t = \frac{1}{1 + \alpha \Delta t} \tag{14}$$

此处 α 为衰减速率参数，其值默认为 0.2。 Δt 为当前时刻与行为发生时间的时
间差，以天为单位。其后要构建用户-博主互动强度矩阵：

$$I_{u,b} = \sum_{k=1}^4 \beta_k \cdot \sum_{t \in T} w_t \cdot N_{u,b}^{(k)}(t) \tag{15}$$

$N_{u,b}^{(k)}(t)$ 为用户 u 对博主 b 在 t 时刻的第 k 类行为次数（编号顺序为前文所描
述的，观看、点赞、评论、关注分别为 1、2、3、4），行为权重向量 β 为默认值
[0.2,0.3,0.3,0.2]。

接着，构建博主全局热度指标：

$$H_b = \frac{\sum_u I_{u,b} + \gamma F_b}{\max_u (\sum_u I_{u,b})} \quad (16)$$

其中 $I_{u,b}$ 为用户 u 对博主 b 的历史互动总次数,即点赞+评论+关注。 F_b 为博主粉丝数， γ 为粉丝影响因子（此处默认 0.05）。其潜在传播力预测可用改进的 SIR 模型：

$$\frac{dS}{dt} = -\beta SI + \mu R \quad (17)$$

$$\frac{dI}{dt} = \beta SI - \gamma I \quad (18)$$

$$\frac{dR}{dt} = \gamma I - \mu R \quad (19)$$

其中，状态变量 S 为潜在用户, I 为传播用户, R 为免疫用户。他们通过用户关系网络传播。

然后，需要融入双通道预测引擎，个性化推荐通道和热度驱动通道

$$P_{u,b}^{personal} = \sigma \left(\theta_1 I_{u,b} + \theta_2 \sum_{v \in N(u)} I_{v,b} \right) \quad (20)$$

$$P_b^{hot} = \frac{\exp(\phi H_b)}{\sum_{b'} \exp(\phi H_{b'})} \quad (21)$$

其中， σ 为 sigmoid 函数， $N(u)$ 为用户 u 的社交邻居， ϕ 为温度参数（此处默认为 1.0）。

最后，最终关注概率预测可根据下式得到：

$$\hat{y}_{u,b} = \lambda P_{u,b}^{personal} + (1 - \lambda) P_b^{hot} + \epsilon \cdot \delta_{u,b}^{geo} \quad (22)$$

此式中的 λ 为个性化权重（默认 0.6）， $\delta_{u,b}^{geo}$ 为地理匹配系数（0-1）， ϵ 为地理影响因子（默认 0.2）。

除此之外，我们还给这个模型加入动态优化机制。首先是时段敏感预测，定义用户活跃时段概率分布：

$$A_u(h) = \frac{\sum_{d \in D} \mathbb{I}(h \in active_h ours(u, d))}{|D|} \quad (23)$$

其中 D 为历史观测天数， $h \in [0, 23]$ 为小时段。然后，再加入实时反馈修正，构建滑动窗口修正因子：

$$\Delta \lambda = \eta \cdot \frac{\sum_{t=T-24}^T correct(u, t)}{N_{predict}} \quad (24)$$

η 为学习率（默认 0.01）， $correct(u, t)$ 为时段 t 预测正确次数

5.2.2 模型的求解

我们可以加入模型评估体系，采用多维度评估指标：

$$Precision@k = \frac{TP}{TP + FP}, \quad Recall@k = \frac{TP}{TP + FN} \quad (25)$$

$$F1@k = 2 \cdot \frac{Precision@k \cdot Recall@k}{Precision@k + Recall@k} \quad (26)$$

k 为主要评估基准,此处令其值为 5。

可得到以下数据：

表 3 题目 2 结果

用户 ID	U7	U6749	U5769	U14990	U52010
新关注博主 ID	B23,B27,B7	B17,B24	—	B12,B15,B24	B13,B17

5.3 题目 3

5.3.1 模型的建立

首先我们需要建立在线预测模型判断用户当天是否使用平台。特征工程里需要包含：

- 1.目标星期活跃次数，即用户过去在目标日期对应星期几的互动次数
- 2.活跃天数，即用户在历史数据中存在行为的天数
- 3.活动总数，即用户在统计时间内所有互动行为的总次数。
- 4.最近活跃间隔，即用户最后一次互动到 2024.7.20 的天数差，此为反映近期活跃度的指标之一。

依此，我们可以得到以下式子：

$$P_{\text{在线}} = 0.4 \times I_{\text{目标星期活跃}} + 0.3 \times \frac{\text{活跃天数}}{D_{\max}} + 0.2 \times \left(1 - \frac{\text{最近活跃间隔}}{30} \right) + 0.1 \times \frac{\text{活动总数}}{C_{\max}} \quad (27)$$

其中， $I_{\text{目标星期活跃}}$ 是一个二值变量。当历史中目标星期有互动时其值为 1，否则值为 0； $D_{\max}$ 表示全体用户活跃天数的最大值； $C_{\max}$ 表示活动总数的 90% 分位数，可有效降低极端值的影响。而式子中的 0.4、0.3、0.2、0.1 为经验权重，反映不同特征对在线预测的贡献度。

接着，我们可以令判定阈值为 0.5，设置下面这一判定规则来预测用户是否在线：

$$\text{预测结果} = \begin{cases} \text{在线,} & P_{\text{online}} \geq 0.5 \\ \text{离线,} & \text{其他} \end{cases} \quad (28)$$

然后，构建互动博主预测模型。可以定义综合互动指数 $S_{u,b}$ 为用户 u 对博主 b 的多种互动行为的加权和：

$$S_{u,b} = \sum (\mathbb{k}_1 \cdot \text{点赞次数} + \mathbb{k}_2 \cdot \text{评论次数} + \mathbb{k}_3 \cdot \text{关注次数}) \tag{29}$$

此处依据题意，综合互动指数为点赞、评论、关注数量的总和，即权值 $\mathbb{k}_1=\mathbb{k}_2=\mathbb{k}_3=1$ 。

最后建立可量化的筛选规则。先提取每个在线用户与所有博主的历史互动数。然后把 $S_{u,b}$ 从高到低排序，选取前 3 名博主。若互动数相同，优先选择最近互动的博主

5.3.2 模型的求解

筛选特定用户，若 $P_{\text{在线}} \geq 0.5$ ，则输出博主 ID1、ID2、ID3（按互动数降序排列）。

表 4 题目 3 结果

用户 ID	U9	U22405	U16	U48420
博主 ID 1	B13	B47	—	B5
博主 ID 2	B24	B59	—	B21
博主 ID 3	B3	B42	—	B2

（U16 用户在 2024.7.21 不在线）




图 5 2024-07-21 用户在线概率分布




图 6 2024-07-21 预测互动热度最高的 TOP20 博主




图 7 2024-07-21 不同概率阈值下用户数量




图 8 2024-07-21 用户活跃间隔与预测在线概率关系

5.4 题目 4

5.4.1 模型的建立

针对问题 4 的建模思路可拆解为以下两个核心阶段，结合用户历史行为规律与博主全局热度进行综合预测。

首先要建立用户在线时段预测模型。先将历史数据中的时间戳转换为星期几和小时，并确定目标日期 2024.7.23 为星期二，即对应星期指数=1。接着，对每个用户，筛选其历史记录中同为星期二的数据。若无，则采用全时段数据。同时，按下式统计各小时活跃频率：

$$P(h|u) = \frac{N_{u,h}}{\sum_{h=0}^{23} N_{u,h}} \quad (30)$$

其中 $N_{u,h}$ 为用户 u 在小时 h 的活跃次数。关于候选时段的筛选，在高概率时段和选择 $P(h|u) \geq \theta$ 的时段（默认 $\theta=0.2$ ）。若无可达阈值时段，则取概率前三的时段。

接着，参照前文（16）式，建立用户-博主互动预测模型。先量化博主热度

指标，计算全局互动热度：

$$H_b = \frac{\sum_u I_{u,b}}{\max_{b'} (\sum_u I_{u,b'})} \quad (31)$$

此外，构建用户时段互动基数：

$$C_{u,b,h} = \sum_{t \in T_{u,h}} \delta_{t,b} \quad (32)$$

其中， $\delta_{t,b}$ 表示用户 u 在时段 h 对博主 b 的互动次数。然后构建综合评分函数，把个性化基数与全局热度给结合起来：

$$S_{u,b,h} = C_{u,b,h} + \lambda H_b \quad (33)$$

这里的 λ 为热度修正参数，此处默认为 0.1。最后，可以构建最优匹配算法，对每个候选时段，选择该时段内评分最高的博主。然后按评分降序排列，优先选取不同时段 Top3 组合，避免时段的重复。

5.4.2 模型的求解

当且仅当用户存在预测在线时段时，输出结果。随后，对每个用户，按评分从高到低依次选取三个不同时段的博客主。时段描述格式化为"HH:00-(HH+1):00"的 24 小时制区间。

由此可得到结果如下：




图 9 问题 4 结果

表 5 问题 4 结果

用户 ID	U10	U1951	U1833	U26447
博主 ID 1	B4	B21	B15	B45
时段 1	01:00-02:00	16:00-17:00	03:00-04:00	15:00-16:00
博主 ID 2	B2	B68	B21	B59
时段 2	02:00-03:00	15:00-16:00	03:00-04:00	20:00-21:00
博主 ID 3	B7	B76	B5	B13
时段 3	15:00-16:00	01:00-02:00	01:00-02:00	15:00-16:00

六、模型评价与改进

6.1 问题 1

6.1.1 模型的优点

1. 特征工程全面

滑动窗口统计能够有效捕捉短期趋势。此外，滞后特征保留历史关键节点信息。而星期几的这类时间特征构建出周期性模式，趋势特征 MA 能够平滑噪声干扰。

2. 模型选择合理

XGBoost 适合处理数值+类别这种混合型特征。加入正则化项 λ, γ 能够有效控制过拟合。树模型也能自动处理特征非线性关系。

3. 工程实现优势

日粒度聚合平衡时效性与计算效率，并且去重计数能保证新增关注数的准确性。

6.1.2 模型的缺点

XGBoost 对长期时序依赖建模能力有限，且点预测缺乏不确定性估计。

6.1.3 模型的改进

可以构建用户-博主二部图特征，引入 LSTM 与 XGBoost 联合模型。




图 10 问题 1 的改进策略

6.2 问题 2

6.2.1 模型的优点

三层递进式框架（数据-特征-预测）符合机器学习最佳实践。个性化+热度驱动的双通道机制能够兼顾微观行为与宏观传播。此外，动态优化模块能实现模型在线学习

6.2.2 模型的缺点

热度通道的玻尔兹曼分布 $\phi=1.0$ 缺乏适应性

6.2.3 模型的改进

优化玻尔兹曼分布

$$\phi_b = 1 + \frac{\sigma_b}{\max_b \sigma_b} \quad (34)$$

依此，便能有效解决了原模型在处理头部博主时区分度不足的问题。

6.3 问题 3

6.3.1 模型的优点

1.特征设计有效

目标星期活跃次数捕捉用户周期性行为模式，能较好反映用户的行为。最近活跃间隔有效反映用户活跃衰减特性。活动总数也能提供用户整体活跃水平的基准评估。

2.计算效率优势

线性加权公式计算复杂度 $O(1)$ ，计算量小，适合实时预测排序。筛选规则时间复杂度 $O(n \log n)$ ，工程实现简单，模型构造快捷。

6.3.2 模型的缺点

本模型受题干限制，其固定权重缺乏个性化适配

6.3.3 模型的改进

优化其机器学习模型：




图 11 问题 3 的改进策略

6.4 问题 4

6.4.1 模型的优点

1. 双因素融合机制

个性化基数可以保留用户微观行为特征。此外，全局热度 H_b 引入群体智能，缓解数据稀疏问题。并且，加权参数 $\lambda=0.1$ 能够平衡个性与热度。

2. 工程实现优势

将时段离散为 24 小时，降低计算复杂度。其实时性也能很大程度满足在线预测需求。

6.4.2 模型的缺点

热度指标 H_b 受马太效应影响，可能压制新晋博主。

6.4.3 模型的改进

将热度指标优化：

$$H_b^{\text{new}} = \frac{H_b}{\log(\text{age}_b + 2)} \quad (35)$$

相较于原数值，改进后能够有效抑制头部效应。

七、参考文献

- [1] Wang Y , Wang L , Li Y ,et al.A Theoretical Analysis of NDCG Type Ranking Measures[J].Journal of Machine Learning Research, 2013.DOI:10.48550/arXiv.1304.6480.
- [2]徐吉.基于协同过滤和矩阵分解的推荐系统研究与应用[D].宁波大学,2019.
- [3] Chen T , Guestrin C .XGBoost: A Scalable Tree Boosting System[J].ACM, 2016.DOI:10.1145/2939672.2939785.
- [4]李静远,李令凯,李博,等.一种基于随机森林和 XGBoost 模型的社交媒体机器人检测方法及系统:202311170452[P][2025-05-04].
- [5]杨曦,刘艳华.改进的 SIR 模型在微博信息传播中的应用[J].科技广场, 2015(2): 5.DOI:10.3969/j.issn.1671-4792.2015.02.002.
- [6] Hochreiter S, Schmidhuber J .Long Short-Term Memory[J].Neural Computation, 1997, 9(8):1735-1780.DOI:10.1162/neco.1997.9.8.1735.
- [7] Zhou T , Kuscsik Z , Liu J G ,et al.Solving the apparent diversity-accuracy dilemma of recommender systems[J].Proceedings of the National Academy of Sciences of the United States of America, 2010, 107(10):4511-4515.DOI:10.1073/pnas.1000488107.